

Техническое задание на пилот

«AI аватары HR и автоматизация видеособеседований на джобборде JobAI»

1. Общая гипотеза, подгипотезы

Тестируется общая пользовательская гипотеза (продуктовая):

- будут ли живые кандидаты проходить в онлайн (через zoom, решение через WebRTS) с цифровыми AI аватарами HR компаний. Проходить, значит: общаться, отвечать на вопросы, задавать вопросы и т.д.

Тестируются следующие подгипотезы (технологические):

- будет ли тормозить AI аватар при общении или имитация видеособеседований будет на достаточном высоком уровне (даже при плоском аватаре - фото)?
- можно ли интегрировать указанное общение через zoom?
- как быстро можно оцифровывать аватаров с фото, сколько длится время обучение (минимальное, максимальное, оптимальное)?
- стоимость оцифровки + обучение AI аватаров (оптимальное)?
- оптимальные вводные данные для оцифровки AI аватаров (голос, фото и т.д.)?
- какая нужна инфраструктура (кластеры видеокарт H100 / 200 или других)?
- сколько стоит поддержания 1-го видеособеседования (real-time) в продолжительности 30/60 минут и более?
- как увеличиваются мощности (в т.ч. стоимость их содержания) когда запараллеливаются несколько одновременных видеособеседований (real-time)?
- прочее

2. Вводные данные

Для Заказчика пилот необходимо реализовывать в следующий последовательности этапов:

Этап 1

1. Тестирование онлайн видеособеседований в real-time (при этом AI аватары HR - плоский, фото);
2. Тестирование в **zoom (обязательно)** и через другие возможные решения - **WebRTS и т.д. (опционально)**;

3. Интегрируется RAG система, через которую «скармливается» текстовая вакансия - система/HR аватар должна «все» знать про вакансию и уметь отвечать на вопросы кандидатов, хотя бы частично/выборочно.
4. Проверяется «живость» общения в real-time:
 - отсутствие задержек;
 - понимание реплик кандидатов;
 - умение отвечать на вопросы кандидатов (RAG в части вакансий);
 - производительность инфраструктуры и стоимость поддержания в течение 30/60 минут и более

Переход на стадию Этапа 2 производится только при положительных результатах Этапа 1 (за исключением стоимости поддержания - здесь условно все равно).

Соответственно, затраты на пилот также идут последовательно, сначала на Этап 1, после положительных результатов - на Этап 2 и далее.

Этап 2

1. Тестирование создания/оцифровка AI аватаров (HR) на базе необходимых дата-сетов: фото, запись голоса и т.д.;
2. Минимальный объем дата-сетов и их качество?
3. Время обучения AI аватаров (HR): минимальное, максимальное, оптимальное;
4. Стоимость создания/обучения AI аватаров?
Как можно данной стоимостью управлять, уменьшать?
5. Стоимость содержание инфраструктуры под создание и использование AI аватаров (HR)

3. Совмещение MVP с пилотом

У Команды в приоритете выпуск MVP 1.0 (JobAI) в соответствии с внутреннем графиком.

Общее продолжительность работы над пилотом **не более 3 месяцев**. Если на Этапе 1 будут отрицательные результаты, то пилот сразу останавливается.

Работа над данным пилотом должна исходить из пропорции:

- MVP = 2/3 от общего рабочего времени;
- Пилот (AI аватары) = 1/3 от общего рабочего времени.

При этом рабочее время планируется следующим образом (базовый вариант):

- с 10:00 до 16:00 (5 рабочих часов + 1 час обед) - MVP 1.0.
- с 16:00-17:00 до 19:00 (3-2 рабочих часа) - пилот (AI аватары)

Back Заказчика может уделять больше времени на пилот.


Если на MVP 1.0 есть срочные текущие рабочие задачи, пилот в это день может быть полностью отложен. Также по прямому указанию Руководителя возможно локальное перераспределение времени в течение рабочего дня и недели.

4. Этап 1

Проведение видеособеседований в zoom (или другое решение) с плоским AI аватаром.

Достаточно добавить фото - см. ниже.


Этап 1



Под положительными результатами Этапа 1 подразумевается:

- минимальная задержка со стороны AI аватара в диалоге (имитация живого разговора между двумя собеседниками)
- задавание вопросов AI аватаров происходит максимально человекоподобным языком (где нужны паузы, где нужна интонация и т.д.)
- в сессии вопросов и ответов (когда кандидат задает вопросы AI аватару по вакансии) - система понимает суть вопроса и качественно отвечает с учетом «скормленной» ранее вакансии (RAG);
- прочее

Этап 2, если на Этапе 1 достигнуты положительные результаты



Тестируется базовая вещь - возможность организации видеособеседование в real-time

При этом важны:

- «слышание» кандидатов
- время задержки при ответе
- качество ответов на вопросы по вакансии

Предусмотреть:

- загрузка обязательных реплик AI аватара (приветствие, прощание и т.д.)
- загрузка обязательных вопросов/подвопросов для AI аватара (соответствует конкретной специальности). На стадии пилота – 1 уровня вопросы.
- загрузка текстовой вакансии (по которой проводится видеособеседование) - через RAG - см. ниже

RAG система:

Кандидаты должны иметь возможность задать вопросы AI аватару.

Если данные вопросы относятся к самой вакансии, AI аватары (по «скормленной» ранее текстовой вакансии) должны мочь на них ответить. На произвольные вопросы (не касающиеся вакансии) AI аватары должны давать общепринятые ответы.

5. Эмблема, упоминание Nullxes

Во время пилота **не вставлять** («в каждую дырку») эмблему и упоминания о компании Nullxes. Авторские права не будут нарушены, поэтому такое навязчивое «брендирование» на стадии совместного пилота просто неуместно.

6. Владение/управление инфраструктурой пилота

При реализации пилота необходимо обеспечить безопасность миграции архитектуры пилота под управление в дальнейшем Заказчиком.

Это означает, что на самом начале организации пилота необходимо:

- следить на каких мощностях размещается решение, код и т.д.
- провести анализ на предмет можем ли мы разместить указанное решение на своих мощностях (с учетом стоимости)
- если нет, сразу запрашивать:
 - актуальные логины/пароли
 - настройки
 - спецификации
 - аккаунты

Код (в своей части) Backend Заказчика документирует в Swagger.


Хранение кода предусмотреть в репозиториях Заказчика (GitLab).

Для этого Backend Заказчика создается отдельную директорию/ветку и раздаёт соответствующие права и доступы участникам пилота.

По итогам пилота Заказчик должен полностью владеть/управлять инфраструктурой, на базе которой строился/тестировался пилот.

Если в процессе реализации пилота не будут предоставлены доступы, настройки и т.д. - пилот до выяснения должен быть полностью остановлен и привлечено Руководство.

7. Диаграмма взаимодействия подсистем



8. Общие сведения по Zoom API/SDK

Stream API (web) по Zoom API: [Ссылка](#)

Более общая документация по Zoom API: [Ссылка](#)

По всей видимости, Zoom не дает работать с сырыми (raw) видеоданными через Web SDK. Web SDK связывает фронт-энд (компоненты браузера вроде Canvas, HTML audio и прочих) и Zoom API.

Вероятнее всего, для нужд передачи потокового видео понадобится на C++ разработать небольшое приложение под OS Linux, которое позволит с применением буферизации и/или транскодирования, или же напрямую, отправлять видеопоток из системы ИИ бота/аватара в Zoom API. [Реализация описана здесь](#).

При этом такие базовые функции, как авторизация, создание встречи, и т.д. реализуемы через Web SDK.

Примечание по звуку: Zoom Linux API не поддерживает создание аудио потока на основе буферов. Для реализации звука необходимо использовать

“виртуальный микрофон” и “виртуальный источник звука”, необходимо изучение подобных open-source решений под OS Linux (pulse audio, jack?). Описание работы со звуком в Linux Zoom SDK [здесь](#).

Так как на первом этапе собеседование происходит без видео со стороны чат-бота, достаточно реализовать аудио-клиента, предлагаемый язык - C++, выбор исполнителя - в процессе.

9. Frontend

<будет позже>

10. DevOps и окружение

Backend выполняется в структуре приложения JobAI, но на отдельном сваггере и отдельном корневом эндпойнте.

11. Инфраструктура

Команда JobAI готова выделить в рамках своего физ. сервера новую виртуальную машину, где будут работать одновременно Nullxes AI решение, Zoom micro-client, Virtual audio I/O.

12. Zoom micro-client

Разработчик Nullxes должен выбрать предпочтительный способ формирования аудиопотоков ввода-вывода: streaming client/server, буфер PCM данных, или другие способы. Это будет учитываться при разработке микро-клиента.

Помимо самого клиента, подбираются или реализуются как форки опер-сорсных систем решения по коммутации потоков ввода-вывода и виртуальных аудио I/O (mic, speaker). Эти аудиоустройства должны быть запущены при запуске системы.

13. Backend

13.1. Общие сведения

Backend представляет из себя отдельный путь и swagger. Его задача - обеспечить хранение настроек, вопросов по специальностям, хранение запланированных собеседований, возможно взять на себя взаимодействие с

Zoom Web API - для получения ссылки на встречу, скачивания аудио/видеозаписей собеседования.

13.2. Авторизация

Используется статический ключ в HTTP заголовке Authorization.

13.3. Основные настройки

Backend обеспечивает хранение и отдачу следующих данных:

- Приветственная реплика - текст. Содержит также шаблонную подстановку `{{job_title}}` - позволяет по производимому видеособеседованию подставить (без склонения) название должности. Например: "Здравствуйте, это видеособеседование по вакансии ETL-инженер (senior). Как я могу к Вам обращаться?".
Прим. А.С.: определить, у кого происходит подстановка (backend? Nullxes?). Также подставляется имя кандидата - `{{first_name}}`, название компании `{{company_name}}`
- Финальная реплика - аналогично, с подстановкой при необходимости `{{job_title}}`, `{{first_name}}`, `{{company_name}}`

Будут отдаваться для Nullxes по запросу `/questions/general`

13.4. Специальности, вопросы по специальностям

Backend хранит вопросы по специальностям. Ниже приведена структура данной конфигурации в контексте прототипа.

Корень:

Поле	Тип	Описание
<code>specialties</code>	Массив	Массив объектов Specialty

Объект Specialty:

Поле	Тип	Описание
<code>id</code>	Число	Уникальный численный идентификатор специальности, напр. 1
<code>name</code>	Строка	Русскоязычное название специальности, например "Разработчики"

questions	Массив	Массив объектов Question
-----------	--------	--------------------------

Объект Question:

Поле	Тип	Описание
text	Строка	Текст вопроса (без шаблонных подстановок)
order	Число	Порядковый номер вопроса, начиная с 1. Должны следовать без разрывов - 1, 2, 3, 4, и так далее.

Для Nullxes будет реализован эндпоинт GET /questions/by_specialty/:id - где id это идентификатор специальностей. Взять идентификатор специальности можно будет из сущности «Собеседование».

13.5. Сущность «Собеседование»

Где указано «только чтение» - данные создает backend, они не указываются при создании собеседования.

Поле	Тип	Описание
id	Число	Уникальный численный идентификатор собеседования, напр. 1
jobTitle	Строка	Должность
vacancyText	Строка	Вспомогательная информация по вакансии для RAG-системы. Максимальное количество символов определяет Nullxes
specialtyId	Число	Идентификатор специальности
companyName	Строка	Название компании
candidateFirstName	Строка	Имя кандидата
candidateLastName	Строка	Фамилия кандидата
zoomLink	Строка	Ссылка на zoom встречу, генерируется на Backend Только чтение

createdAt	Дата/время GMT	Дата/время создания собеседования Только чтение
meetingAt	Дата/время GMT	Дата/время проведения собеседования в Zoom
status	Строка	<i>См. раздел “Статусы собеседований”</i>
statusChangeAt	Дата/время GMT	<i>Дата/время последнего изменения статуса</i>
videoFilename	Строка, может быть null, по умолчанию null	Название видеофайла на S3 (полный путь) Только чтение
audioFilename	Строка, может быть null, по умолчанию null	Название аудиофайла на S3 (полный путь) Только чтение

Backend реализует методы, которые будут описаны в Swagger:

- Создание собеседования (при этом создается еще и ссылка на zoom, где будет проходить собеседование и выдается в ответе)
- Удаление собеседования
- Получение собеседований в порядке убывания с базовой пагинацией
- Получение 1 объекта “собеседование”
- Смена статуса собеседования

13.6. Статусы собеседований

Статусы перечислены в таблице в том порядке, в котором они могут появиться.

Статус	Описание
pending	Только что создали собеседование, но его еще не зарегистрировала у себя система Nullxes
received	Nullxes забрала собеседование к себе
in_meeting	В настоящий момент проходит встреча между ботом и кандидатом
stopped_during_meeting	Система Nullxes прервала

	собеседование в процессе самого собеседования (на основе решения бота, или кандидат не явился)
completed	Собеседование завершено

Также в данную таблицу могут быть внесены эти и другие статусы:

- `meeting_not_started` - какая-то ошибка произошла на старте, например чат-бот не смог зайти в собеседование
- `canceled` - отменено еще до начала

13.7. Межсервисное взаимодействие «Backend <-> Nullxes»

Ниже перечислены варианты **инициализации** взаимодействия backend <-> Nullxes, которые выбираются разработчиками совместно.

1. **Polling:** Система Nullxes может периодически запрашивать список планируемых собеседований через специальный эндпойнт (`interviews/get_pending`).
2. **Webhook:** Backend сам обращается с Nullxes после добавления нового собеседования по http протоколу.

Таким образом, в polling инициализации запрос периодически иницирует Nullxes (опрашивает backend), а в webhook запрос иницирует backend.

Также необходимо предусмотреть **смену статусов** собеседования в backend. Его предпочтительнее реализовать через **Webhook**: Nullxes запрашивает метод бэкэнда, например `POST interviews/set-status`, в котором передает `interviewId` и `status`.

Примечание: так как это прототип, реализация failover (повторы при недоступности backend или Nullxes в webhook-взаимодействии) **не обязательна**.

13.8 .Сохранение результатов

Когда Nullxes выставил на backend статус `completed` или `stopped_during_meeting`, backend в фоновом режиме через Zoom Web API скачивает аудио и видеозапись собеседования. Либо [эти](#) методы, либо [эти](#). После скачивания они отправляются на хранение в S3 бакеты.

<...продолжение следует...>